

OPENCLASSROOMS

Réalisez une application de
recommandation de contenu



Kamel BENSTAALI
AI Engineer

Sommaire

- Contexte & Mission
- Jeu de données
- Modélisation & Évaluation
 - Les 3 approches
 - Approche Hybride
- Déploiement : Architecture MVP & Démonstration
- Architecture Cible & Perspectives
- Conclusion & Remerciements

Contexte et problématique métier



Contexte

- **Entreprise : My Content** est une start-up qui veut encourager la lecture en **recommandant des contenus pertinents** pour ses utilisateurs.
- **Notre équipe** : Nous sommes les cofondateurs. Je suis le CTO en compagnie de notre CEO Samia.
- **Rôle** : Créer un MVP (Minimum Viable Product) d'un moteur de recommandation performant, capable de fournir un Top 5 d'articles pertinents en temps réel pour les utilisateurs.

Jeu de données

Présentation

Source : Portail d'actualités Globo.com (open-source).

Composition : Deux grandes familles de données :

1. Historique des lectures (Comportement des utilisateurs).
2. Métadonnées du catalogue (Informations sur les articles).
3. Contenus des articles codés en embeddings.

Jeu de données

Structure des fichiers (Clics & Articles)

Fichiers de Clics : Sessions des utilisateurs (ID Utilisateur, ID Article, Horodatage).

Fichier Articles : Informations textuelles (Catégorie, Date de publication, Nombre de mots).

Fichier Embeddings : Format vectoriel pré-calculé du texte de chaque article (250 dimensions).

Jeu de données

Analyse Exploratoire (EDA) & Optimisation PCA

Résultats clés :

- **2 988 181** interactions (clics)
- **322 897** utilisateurs uniques
- **364 047** articles disponibles au catalogue
- **9.25 clics/utilisateur** en moyenne
- **461** catégories uniques d'articles


Jeu de données

Analyse Exploratoire (EDA) & Optimisation PCA

Courbe de Pareto des catégories d'articles



Distribution du nombre de catégories lues par utilisateur



Loi de Pareto : 67 catégories (sur 461 au total) concentrent à elles seules 80% du catalogue d'articles



Utilisateurs Mono-catégorie (1 seule) : 8.88 %



Utilisateurs Multi-catégories (2 et +) : 91.12 %

Modélisation

Approche d'évaluation et métriques

Validation Chronologique :

Méthode "Leave-One-Out" stricte (Prévention du *Data Leakage*).

Métriques Métier :

- **Hit Ratio @ 5 (HR@5)** : L'article cible est-il dans le Top 5 ? (Pertinence).

$HR = (\text{Nombre de Hits}) / (\text{Nombre d'Utilisateurs testés})$

- **MRR @ 5 (Mean Reciprocal Rank)** : L'article est-il placé en 1ère position ? (Précision du tri).

Application d'un poids sur le hit en fonction du rang

- **Coverage (Couverture)** : Le modèle recommande-t-il tout le catalogue ou s'enferme-t-il dans une bulle ? (Diversité).

Métriques Cloud (Serverless) :

- **Latence (ms)** : Temps d'exécution de la requête.
- **Peak Memory (RAM)** : Empreinte mémoire des matrices.

Modélisation

Benchmark des approches du Filtrage Collaboratif

Principe : Les utilisateurs qui ont lu A ont aussi lu B" (Aucune analyse de texte).

Les 2 Modèles en compétition :

- **SVD (Singular Value Decomposition)** : Factorisation de matrice classique (bibliothèque `Surprise`).
- **ALS (Alternating Least Squares)** : Modèle optimisé pour les matrices creuses et les données implicites (bibliothèque `Implicit`).

Enjeu : Trouver l'algorithme le plus performant des deux pour nos "Warm Users" (utilisateurs avec un historique).

Modélisation

Résultats du benchmark Collaboratif

Victoire écrasante de l'ALS :

- **Hit Ratio @ 5** : ALS (14.39%) vs SVD (0.01%).
- **Précision (MRR)** : ALS (0.08) vs SVD (~0).
- **Coverage** : **ALS (0.58%) vs SVD (0.40%)**

Performances Cloud (API) :

- **Latence** : ALS (1.27 ms) vs SVD (172.74 ms) => 135 fois plus rapide !
- **Empreinte RAM** : ALS (69 Mo) vs SVD (138 Mo).

Choix Retenu :

- L'algorithme **ALS**.

Modélisation

Benchmark des approches du Filtrage Content-Based

Principe : Ne regarder que le sens du texte. Résout le problème du **Cold-Start** des nouveaux articles !

La donnée clé : Les "Embeddings" (réduits de 250 à 50 dimensions par PCA).

Les 2 Distances :

Similarité Cosinus : Mesure l'angle entre deux vecteurs (standard absolu en NLP).

Distance Euclidienne : Mesure la distance géométrique directe entre deux vecteurs.

Modélisation

Résultats du benchmark Sémantique

Résultats très similaires entre les deux méthodes:

Pertinence Métier (Hit Ratio @ 5) :

- Cosinus : 1.03 %
- Euclidienne : 1.05 %

Précision du Classement (MRR @ 5) :

- Cosinus : 0.0064
- Euclidienne : 0.0062

Diversité (Coverage) :

- Cosinus : 2.83 %
- Euclidienne : 2.84 %

Performances Cloud (Inférence unitaire) :

Latence :

Avantage au **Cosinus** (~89 ms) vs Euclidienne (~123 ms).

Empreinte RAM :

Les matrices d'Embeddings PCA pèsent seulement **72 Mo**.

Choix Retenu :

La **Similarité Cosinus**.

Modélisation

Approche par popularité

L'objectif : Gérer le "Cold-Start Utilisateur" absolu (Un lecteur qui arrive pour la toute première fois).

Le problème de la popularité basique : Toujours recommander les mêmes vieux articles.

La solution : Le **Time Decay** (Déclin Temporel).

- Le score de popularité d'un article diminue avec le temps.
- Les "Breaking News" prennent le pas sur les articles d'hier.

Formule:

$$\text{Score} = (\text{Nombre d'utilisateurs uniques}) / (\hat{\text{Âge de l'article en heures}} + 1)$$

Modélisation

L'Hybridation et l'Optimisation Scientifique

Le concept : Fusionner les 3 signaux en un score final hybride.

La méthode : Normalisation MinMax (0 à 1) + Moyenne Pondérée.

L'optimisation (Optuna) : Approche scientifique par IA pour trouver les "poids" parfaits.

Score Hybride = $(\alpha \times \text{ScoreALS}) + (\beta \times \text{ScoreContent}) + (\gamma \times \text{ScorePopularité})$

(Avec $\alpha + \beta + \gamma = 1$)

- **Poids de l'ALS** : ~67% (Le moteur principal).
- **Poids du Content-Based** : ~14% (Le soutien sémantique).
- **Poids de la Popularité** : ~19% (Le joker tendances).

Modélisation

Performances du Modèle Hybride Final

Hit Ratio Global : 15.53 % (Performance supérieure à l'ALS seul).

MMR: 0.09

Coverage: 0.07%

Le point fort : Excellente gestion des nouveaux lecteurs.

- Hit Ratio (Anciens) : ~9.8 %
- Hit Ratio (Nouveaux) : **21.11 % !**

Conclusion Modélisation : Un moteur robuste, polyvalent et prêt pour le Cloud.


Modélisation

Comparaison en performances

Modèle	Hit Ratio @ 5	MRR @ 5	Coverage
Content-Based (Cosinus)	10.30 %	0.0064%	2.83%
ALS (Collaboratif)	14.39 %	0.0838%	0.58 %
Hybride (ALS + CB + Pop)	15.53 %	0.0898%	0.07 %

Architecture Technique

- **Back-End** : API Serverless (Azure Functions) -> Scalabilité & Coûts réduits.
- **CI/CD**: Pour mise à jour de l'API à chaque push de code.
- Séparation du code API (Azure Functions) et des artefacts (BlobStorage).
- **Front-End** : Application Streamlit moderne (ne proposant que la fonctionnalité de recommandation d'articles à un utilisateur actuellement).
- **Résilience** : Système de Fallback intégré en cas de panne de l'API.



Interface graphique

GloboNews AI

Votre moteur de recommandation intelligent

 Qui êtes-vous ?

Saisissez votre ID Utilisateur (ex: 0, 42, 25, ou 999999 pour un nouvel utilisateur) :

Découvrir mes recommandations

Voici vos recommandations sur mesure !

 Article n°293114

Catégorie : 421

Pertinence : 74.5%

 Article n°284985

Catégorie : 412

Pertinence : 67.1%

 Article n°272218

Architecture Cible & Perspectives

Passage à l'échelle :


Automatisation de l'entraînement (Azure Data Factory).

Gestion des ajouts « Utilisateurs & Articles » :

- **Nouvel Utilisateur** : Détecté en direct (Popularité) puis intégré la nuit (Ré-entraînement ALS).
- **Nouvel Article** : Poussé immédiatement par le modèle Content-Based (Analyse Sémantique).

Autres perspectives d'évolution :

- Intégration de features temporelles (Matin vs Soir).
- Passer à une framework web plus solide que Streamlit.



Conclusion

- Objectif atteint : Moteur hybride supérieur aux approches classiques, réactif et sécurisé capable de proposer des recommandations.
- Réponse apporté par rapport à la futur fonctionnalité d'ajout de nouvelles utilisateurs et articles.
- Prêt pour le déploiement Cloud



Merci
Avez-vous des questions ?